

HW1 Report

jimmy60504

2026-04-16

Contents

Links	1
Problem 1	3
Problem 1 作答	3
問題背景	3
(a) Best model 的 training/test loss curve	3
(b) Hyperparameter/configuration 比較表	4
(c) Fourier spectrum 分析	7
Problem 2	11
Problem 2 一作答	11
(a) 重現 Fig. 6 一超球面資料集	11
(b) 決策邊界	12
(c) 比較表	14
(d) 討論	14
Problem 3	15
Problem 3 一作答	15
(a) 量子電路設計	15
資料編碼策略	15
變分量子電路	15
量測與後處理	15
實驗設定	16
(b) 測試準確率	16
(c) 比較表	16
(d) 訓練曲線	17
(e) 討論	17

Links

	URL
GitHub	https://github.com/jimmy60504/quantum_computing
Problem 1 HF	https://huggingface.co/spaces/jimmy60504/Data-Reuploading-Demo
Problem 2 HF	https://huggingface.co/spaces/jimmy60504/QML-Classifer-Explorer
Problem 3 HF	https://huggingface.co/spaces/jimmy60504/Hybrid-QNN-Explorer

Problem 1

Problem 1 作答

問題背景

本題目標函數為

$$f(x_1, x_2) = \sin(e^{x_1} + x_2)$$

訓練域與測試域刻意不重疊（分別為 $[0, 0.5]^2$ 與 $[0.5, 1]^2$ ），因此模型必須學到可外推的結構，而不只是擬合訓練點的局部形狀。




Figure 1: Train/test domain overview

此函數存在兩個結構上完全不同的精確量子解，奠定了後續超參數搜索的上界與分析框架：

1-qubit same-axis reupload 精確解 (quantum_exact): 在單一 qubit 上依序施加 $R_Y(e^{x_1})$ 、 $R_Y(x_2)$ 、 $R_Y(-\pi/2)$ ，再量測 $\langle Z \rangle$ 。同軸旋轉的角度加法性使電路等效為 $\langle Z \rangle = \cos(e^{x_1} + x_2 - \pi/2) = \sin(e^{x_1} + x_2)$ ，1 個 qubit、0 個可學習參數即可精確表示目標函數（final test MSE $\approx 7.3 \times 10^{-15}$ ）。

2-qubit no-reupload 精確解 (twoqubit_no_reupload): 將 e^{x_1} 與 x_2 分別編碼到兩個 qubit，利用和角公式 $\sin(\alpha + \beta) = \sin \alpha \cos \beta + \cos \alpha \sin \beta$ 從 $\langle X_0 Z_1 \rangle$ 與 $\langle Z_0 X_1 \rangle$ 的線性組合重建目標值，完全不依賴 data reupload（final test MSE $\approx 5.9 \times 10^{-15}$ ）。

這兩條精確解提供了一個方法論上的切入點：與其從一個任意設計的 ansatz 出發去搜索超參數（實驗中這樣做確實難以收斂），不如先從已知可以精確表示目標函數的電路結構開始，再逐步放鬆假設、引入可學習參數，讓模型沿著有意義的結構梯度往 data reuploading 的方向泛化。以下各小題的模型選取與分析均沿此思路展開。

(a) Best model 的 training/test loss curve

最佳模型選取 same_axis_reupload ($q = 1$, $L = 2$)。此配置的電路在每個 layer 中依序施加 $R_Y(e^{x_1})$ 、 $R_Y(x_2)$ 、 $R_Y(\phi_\ell)$ ，利用同軸 reupload 的角度加法性，在量子電路內部自然實現 $e^{x_1} + x_2$ 的組合結構。訓練以 Adam optimizer、

fixed learning rate 0.03、batch size 64、10 epochs 進行。

訓練結果：

- Final train MSE: 6.79×10^{-5}
- Best test MSE: 4.91×10^{-3} (低於題目要求的 0.1)
- Final test MSE: 6.42×10^{-3}




Figure 2: Training vs Test MSE —same_axis_reupload (q=1, L=2)

如圖所示，train MSE 與 test MSE 在整個訓練過程中均單調下降，無過擬合跡象。Test MSE 在第 3 個 epoch 即跌破 0.1 閾值，至第 10 epoch 收斂至約 6×10^{-3} 。Train 與 test 之間的誤差間距（約兩個數量級）反映的是特徵先驗的校準問題：模型雖保住了正確的 additive 幾何結構，但可學習的 scale/bias 參數還未完全對齊 e^{x_1} 的尺度——這是此配置的主要殘差來源，而非過擬合。


(b) Hyperparameter/configuration 比較表

下表比較六種架構配置，涵蓋主要的結構差異：

模型	Q	L	exp(x1) 先驗	# Params	Best Test MSE
same_axis_reupload	1	2		10	4.91e-3
same_axis_rot	1	2		16	5.14e-3
same_axis_poly	1	2	近似	18	2.88e-2

模型	Q	L	$\exp(x_1)$ 先驗	# Params	Best Test MSE
same_axis_raw	1	2		10	3.22e-2
same_axis_twoqubit	2	2		23	6.95e-2
twoqubit_raw_no_reupload	2	1		11	2.03e-1

各模型對應的量子電路如下：



上圖將六組配置的 train MSE（虛線）與 test MSE（實線）畫在同一張圖上，log scale 下兩群自然分開。從 test MSE 可以觀察到明顯的分群：same_axis_reupload 與 same_axis_rot 從第一個 epoch 起就持續下降並突破 0.1 閾值；same_axis_poly 和 same_axis_raw 在中段有所進展但最終穩定在較高水平；same_axis_twoqubit 收斂更慢；twoqubit_raw_no_reupload 的 test MSE 幾乎橫向不動，始終停在 0.2 以上。值得注意的是，train MSE 的排序與 test MSE 幾乎相反——train 收斂最快的未必能外推到測試域——這再次說明本題的核心挑戰在於結構先驗，而非優化本身。

以下為幾個重要觀察：




Figure 3: Train and Test MSE across all configurations

先驗結構是最關鍵的超參數。same_axis_reupload 與 same_axis_raw 的 qubit 數、layer 數、可學習參數數完全相同，唯一差異是前者直接以 e^{x_1} 作為第一個 rotation angle，後者改用 raw x_1 。僅此差異便造成約一個數量級的 test MSE 差距 (4.91×10^{-3} 對 3.22×10^{-2})，說明內部表示是否能對齊 e^{x_1} 遠比其他超參數更重要。

增加參數量不保證改善泛化。same_axis_poly 用 18 個參數試圖以可學習的三次多項式近似 e^{x_1} ，test MSE 反而比 10 參數的 same_axis_reupload 差近六倍。過度的參數自由度在此反而稀釋了結構先驗。值得注意的是，same_axis_poly 的 test MSE 在 epoch 2-4 出現明顯的下凹再回升——這個特徵只有把整段訓練曲線畫出來才能看到，背後的幾何原因與頻率解釋詳見 (c)。

增加 qubit 數不保證改善泛化。same_axis_twoqubit 用 23 個參數和 2 qubits，test MSE 卻是 6.95×10^{-2} ，明顯差於 1-qubit 的版本。額外的 qubit 引入更大的參數空間，同時破壞了原本乾淨的 same-axis additive 結構，造成更難收斂的訓練動態。twoqubit_raw_no_reupload 則更進一步驗證了這點：即便加上 entanglement，若沒有正確的 e^{x_1} 先驗，模型也無法從 raw inputs 自行學出所需的非線性內部表示。

(c) Fourier spectrum 分析

根據 Ref. [1]，data reuploading 電路的輸出可以寫成輸入的有限 Fourier 級數。對於 L 層、1-qubit 的 same-axis reupload，可訪問的頻率集合由電路中每個輸入出現的次數決定：若每個變數在每層各上傳一次，則在第 ℓ 層的貢獻使可達頻率集合擴展一個單位，對 L 層而言最高頻率為 L ，對應的頻譜為

$$f(x_1, x_2) = \sum_{\omega_1 \in \Omega_1, \omega_2 \in \Omega_2} c_{\omega_1 \omega_2} e^{i(\omega_1 x_1 + \omega_2 x_2)}$$

其中 $\Omega_1, \Omega_2 \subseteq \{-L, \dots, L\}$ 。本題目標函數 $\sin(e^{x_1} + x_2)$ 在 x_2 方向只需一個頻率分量 ($\omega_2 = \pm 1$)，但在 x_1 方向的有效頻率取決於 e^{x_1} 的 Taylor 展開，因此需要多層才能捕捉高階分量。




Figure 4: Fourier Spectrum Comparison

然而，單看 2D heatmap 和 Fourier spectrum 有一個實際困難：四組模型的上排 2D 輸出圖在色彩上差異微妙，不容易直

接判斷曲面幾何；spectrum 的能量分佈差異也需要一定解讀門檻。以下先對 spectrum 逐一說明，再用 3D 曲面圖補充，讓頻率空間的差異與幾何行為對應起來。

Target: spectrum 呈現集中的十字型結構，能量主要分佈在低頻的 ω_{x_2} 軸，反映 $\sin(\cdot + x_2)$ 對 x_2 的單頻依賴，以及 e^{x_1} 在測試域上近似線性的緩慢展開。

same_axis_reupload: 主頻位置與 target 對齊良好，十字型結構清晰可見，但整體幅度略低。Spectrum 的這個特徵對應到 3D 曲面上「方向正確、幅度欠校準」的殘差——




Figure 5: same_axis_reupload 3D surface

Train domain 曲面貼合樣本點，弧度正確；test domain 延續了相同的下彎曲率，整體幾何方向正確，與 (a) 中分析的 scale/bias 校準未完全收斂一致。

same_axis_poly: 十字型輪廓尚存，但 ω_{x_1} 方向的能量分佈與 target 明顯不對稱。這個頻率空間的非對稱性對應到一個特殊的幾何失敗：

Poly 最終學出來的 train surface 傾斜方向是反的——曲面從 $x_1 = 0$ 側的高值向 $x_1 = 0.5$ 側往下傾，而 target 在訓練域內的 x_1 方向應是向上的。這代表多項式係數在訓練過程中經歷了一次方向翻轉：模型先在某個較低的 test MSE 暫時駐留，隨後係數繼續更新、整個曲面轉向，穩定到最終的鏡像解。這正是 (b) loss curve 上 epoch 2-4 出現下凹再回升的來源——Fourier spectrum 中 ω_{x_1} 方向能量的不對稱，是這次翻轉留下的頻率空間印記。

same_axis_raw: 十字型能量輪廓尚存，但明顯更為分散，高頻噪訊增加。以 raw x_1 代替 e^{x_1} ，模型試圖用 x_1 的低階 Fourier 分量去近似所需的非線性組合，能量洩漏至不相關的頻率位置——

對應到 3D 上，train domain 曲面比 same_axis_reupload 更平，四個角落的弧度明顯不足；test domain 雖仍有斜度，但幅度偏小，test MSE 約高出六倍。

twoqubit_raw_no_reupload: 十字型結構幾乎消失，能量分佈混亂，只剩極低頻的直流分量 (DC term)。Ref. [1] 指出



Figure 6: `same_axis_poly` 3D surface




Figure 7: `same_axis_raw` 3D surface

電路深度直接決定 Fourier series 的截斷頻率；此模型缺乏 e^{x_1} 先驗且只做一次 encoding，可達頻率集合最為受限，這在 3D 曲面上表現得最為直接——




Figure 8: twoqubit_raw_no_reupload 3D surface

Train domain 曲面幾近一片平板，停在 value 1 附近，四個角落均明顯偏離樣本點——模型退化為對訓練集的加權平均，無法學到任何有效弧度。其直接後果是 test domain 也輸出一個幾乎不彎曲的平面，浮在 $[0.5, 1]$ 的高度，無法跟隨測試點向下彎至負值。這正是 Fourier spectrum 中十字型結構消失的幾何詮釋：模型學不到 $\omega_{x_2} = \pm 1$ 的主頻分量，自然也就無法產生任何方向上的正弦曲率。

綜合兩種視角，本題的核心瓶頸在於：可達的 Fourier 頻率集合是否包含 target 的主頻結構。same_axis_reupload 之所以表現最好，正是因為其電路結構保住了最對齊 target 頻率的組合方式——而這一點，在 Fourier spectrum 中是十字型能量的對齊程度，在 3D 曲面中則是 train 與 test 兩側的弧度是否能同步再現。

Problem 2

Problem 2 — 作答

隨機種子: 11224001。決策邊界圖 ((b)) 使用 2 個量子位元, $n_samples = 200$ (140 訓練 / 60 測試), 訓練 50 個 epoch, 學習率 0.05, 批次大小 32, 最佳 run `q2-1e4-1r8-e50` (explicit encoding layers $LE = 4$, reuploading layers $LR = 8$)。Fig. 6 重現實驗 ((a)) 以系統大小 n (量子位元數 = 輸入維度) 為 x 軸, 從 $n = 2$ 到 $n = 8$, 5 個隨機種子, 固定 4 層電路深度, 使用 n 維超球面資料集。

Problem 2 — Dataset Overview




Figure 9: Problem 2 — Dataset Overview

Circle 資料集為同心圓結構 (外圈 class 0, 內圈 class 1); Moons 資料集為兩個交錯月牙形 (class 0 為上月牙, class 1 為下月牙)。兩者均為非線性可分問題, 藉此考驗三種 QML 方法的決策邊界表達能力。

(a) 重現 Fig. 6 — 超球面資料集

Ref. [3] Fig. 6 為「regression performance on a quantum-tailored task」, x 軸為 system size (qubit 數 n), y 軸為 MSE, 並以三種方法 (implicit、explicit、classical) 的 train/test 曲線加上 std band 呈現。

我們直接以 **系統大小 n (量子位元數 = 輸入維度)** 作為 x 軸, 忠實重現 Fig. 6 的橫軸定義。資料集使用 n 維超球面 (n -sphere binary classification): 外殼 (class 0, radius 1.0) vs. 內殼 (class 1, radius 0.5), 以匹配幾何上的「量子適配任務」。三個模型均推廣至任意 n 量子位元: ring CNOT 拓樸 + ZZ feature map。每個 $(n, seed)$ 組合重複 5 個隨機種子, 陰影為標準差。MSE 採用 Brier score ($MSE = \mathbb{E}[(p - y)^2]$, $p \in [0, 1]$)。




Figure 10: Problem 2 (a) —MSE vs system size n , hypersphere dataset (Fig. 6 style)

三種方法的行為：

- **Data Reuploading** (綠, 對應 paper 的 implicit): 在 $n = 2$ 時表現最佳 (test MSE ~ 0.06), 但 test MSE 隨 n 增加迅速上升, 至 $n = 8$ 達 ~ 0.18 。原因在於固定 4 層電路深度, 面對指數增長的 n 維分類邊界, 模型容量出現瓶頸; train/test 間差距反映輕微過擬合在 n 增大後趨於一致。
- **Explicit** (紅, 對應 paper 的 explicit): train 與 test MSE 從 $n = 2$ (~ 0.145) 平穩上升至 $n = 8$ (~ 0.185), 幾乎無訓練/測試差距。此行為正對應 single encoding 的硬性頻率上限: 即使增加 n , 可達 Fourier 頻率集合仍受 encoding 次數限制, 無法擬合更複雜邊界。
- **Implicit Kernel** (藍, 對應 paper 的 classical): test MSE 從 $n = 2$ (~ 0.07) 緩慢升至 $n = 7-8$ (~ 0.12), 是三者中最穩健的方法。kernel 訓練 MSE 基本維持在 0.06-0.07, 顯示 Gram matrix 擬合不隨 n 退化——量子核函數的 ZZ feature map 對超球面幾何的對稱結構保持較好的 kernel alignment。

(b) 決策邊界

圖中圓形標記為訓練點, 三角形標記為測試點; 紅色為 class 0, 藍色為 class 1; 白色輪廓線為 0.5 決策邊界。

各方法特性如下：

- **Explicit**: 在 circle 資料集上產生的邊界大致呈圓形但不夠精確, 部分樣本被錯誤分類; 在 moons 上邊界較平滑, 但在兩側末端略有偏差, 整體邊界形狀受限於單次 encoding 的低表達能力。

Problem 2 (b) — Decision Boundaries [q2-le4-lr8-e50]




Figure 11: Problem 2 (b) —Decision boundaries (3 × 2)

- **Implicit Kernel**: 在 circle 上形成較緊密的圓形邊界，準確率 96.7%；在 moons 上邊界較不規則，準確率下降至 85.0%，反映量子特徵映射對非對稱幾何結構的適應性較弱。
- **Data Reuploading**: 在兩個資料集上均產生最銳利、最貼近真實分布的決策邊界，測試準確率各達 96.7% (circle) 與 100% (moons)，邊界輪廓緊密包覆樣本點。

(c) 比較表

方法	資料集	測試準確率	可訓練參數 / 核函數計算次數	訓練時間
Explicit	Circle	75.0 %	16 個參數	20 s
Explicit	Moons	83.3 %	16 個參數	20 s
Implicit Kernel	Circle	96.7 %	19,600 次核計算	10 s
Implicit Kernel	Moons	85.0 %	19,600 次核計算	10 s
Data Reuploading	Circle	96.7 %	48 個參數	45 s
Data Reuploading	Moons	100.0 %	48 個參數	45 s

核函數計算次數 = $140 \times 140 = 19,600$ (完整訓練 Gram matrix)。

(d) 討論

Data reuploading 在兩個資料集上均達到最高且最一致的準確率 (各 98.3%)，原因在於將資料重複編碼穿插於可訓練旋轉之間，大幅擴展了相同參數數量下的函數表達能力——相當於在量子特徵空間中實現了更豐富的 Fourier 頻率組合，而不受單次 encoding 截斷頻率的限制 (參見 Ref. [1, 3])。

Implicit kernel 方法在對稱的 circle 資料集上表現良好 (96.7%)，但在 moons 上明顯下降至 85.0%，與 Ref. [3] 的觀察一致——核方法的量子特徵映射較適合幾何結構與量子特徵空間相匹配的資料集。Moons 的非對稱雙月形結構破壞了這種對齊，Gram matrix 所能捕捉的核相似度無法有效分離兩類。

Explicit 模型表現最弱 (circle 75.0%、moons 83.3%)，呼應了論文的論點：單次 encoding 將輸入投影到固定的特徵空間後，即使增加層數 ($LE = 4$)，可達的 Fourier 頻率集合也只取決於 encoding 次數而非可訓練旋轉層數，因此函數表達能力有硬性天花板。

整體結果重現了 Ref. [3] 所報告的方法排序：data reuploading > implicit kernel > explicit。值得注意的是，在 moons 資料集上 kernel 與 explicit 的差距縮小，反映出不規則幾何邊界同時考驗了 kernel 的特徵匹配與 explicit 的表達能力，而 reuploading 對兩種困難的幾何結構均保持穩健。

Problem 3

Problem 3 —作答

隨機種子: 11224001。資料集: CIFAR-10 (50,000 訓練 / 10,000 測試)。Backbone unfrozen, 兩個模型一起端對端訓練 20 epochs, Adam optimizer, batch size 64。

(a) 量子電路設計

資料編碼策略

CNN backbone 輸出的 256 維特徵向量先透過一個經典線性層降維:

$\text{Linear}(256 \rightarrow 8) + \tanh(\cdot) \times$

此步驟將 256-D 特徵壓縮至 8 個數值, 並縮放至角度編碼範圍 $[-\pi, \pi]$ 。接著透過 RY 旋轉進行 angle encoding:

$\text{RY}(x)$ 作用於量子位元 i , $i = 0, 1, \dots, 7$

變分量子電路

每個變分層由單量子位元的可訓練旋轉加上 CNOT 環狀糾纏組成:

對每層 $k = 1, 2, 3, 4$:

$\text{RY}(\theta_k, i) \cdot \text{RZ}(\phi_k, i)$ 作用於每個量子位元 i

$\text{CNOT}(i \rightarrow (i+1) \bmod 8)$ 環狀拓撲糾纏

量子可訓練參數: $4 \text{ layers} \times 8 \text{ qubits} \times 2 \text{ 旋轉} = \mathbf{64}$ 個量子參數。

電路圖示 (以 1 層為例, 8 qubits):

q0: $[\text{RY}(x)] [\text{RY}(\cdot)] [\text{RZ}(\cdot)] \quad X \rightarrow Z$

q1: $[\text{RY}(x)] [\text{RY}(\cdot)] [\text{RZ}(\cdot)] X \rightarrow Z$

q2: $[\text{RY}(x)] [\text{RY}(\cdot)] [\text{RZ}(\cdot)] X \rightarrow Z$

q7: $[\text{RY}(x)] [\text{RY}(\cdot)] [\text{RZ}(\cdot)] \quad X \rightarrow Z$

encoding variational

量測與後處理

對每個量子位元量測 PauliZ 期望值 Z , 得到 8 維的實數向量 (值域 $[-1, 1]$)。再透過線性層映射為 10 類別的 logits:

$\text{Linear}(8 \rightarrow 10) \rightarrow$ 分類 logits

實驗設定

超參數	值
量子位元數	8
變分層數	4
糾纏拓撲	CNOT 環狀 (ring)
梯度計算	backprop (default.qubit)
批次平行化	torch.func.vmap
CNN Backbone	Unfrozen (共同訓練)
優化器	Adam
Epochs	20
Batch size	64

可訓練參數: $\text{Linear}(256 \rightarrow 8)$ [2,056] + 量子電路 [64] + $\text{Linear}(8 \rightarrow 10)$ [90] = **Head 共 2,210 個**; 加上 backbone 56,320, 總計 **58,530 個**。Hilbert space 維度: $2^8 = 256$ 維。

(b) 測試準確率

模型	最佳測試準確率	對應 Epoch
CNN + MLP (基準)	76.46%	Epoch 19
CNN + QNN (8q×4l)	73.70%	Epoch 20

兩者之間差距為 **2.76 個百分點**。

(c) 比較表

模型	測試準確率	可訓練參數	訓練時間 (20 ep)	每 epoch 時間
CNN + MLP	76.46%	58,890	65.5 s	3.3 s
CNN + QNN (8q×4l)	73.70%	58,530	658.7 s	33 s

MLP head 為 $\text{Linear}(256 \rightarrow 10)$ (2,570 params) ; QNN head 為 $\text{Linear}(256 \rightarrow 8) + \text{PQC}(8q, 4L) + \text{Linear}(8 \rightarrow 10)$ (2,210 params)。兩個模型的總參數量幾乎相同 (差 360), 測試準確率差距 2.76%。

訓練速度方面，QNN 使用 `torch.func.vmap` 將 sequential QNode 呼叫向量化，比 MLP 慢約 10 倍（相較於未使用 vmap 的 $4q \times 2l$ 版本慢 311 倍）。

(d) 訓練曲線

Problem 3(d): CNN+MLP vs CNN+QNN Training Curves (CIFAR-10, 20 Epochs)




Figure 12: Training Curves

以下摘要關鍵 epoch:

Epoch	MLP train	MLP test	QNN train	QNN test
1	41.4%	52.3%	32.8%	44.5%
5	64.9%	68.6%	60.2%	62.1%
10	71.2%	73.2%	67.8%	69.6%
15	74.3%	75.9%	71.9%	72.3%
20	75.4%	76.4%	73.6%	73.7%

MLP 從 epoch 1 起就穩定學習，第 15 epoch 後趨於收斂。QNN 的起步準確率 (44.5%) 遠高於舊版 $4q \times 2l$ 電路 (28.2%)，顯示擴大 Hilbert space ($2 = 256$ 維) 有效降低了 barren plateau 的影響。兩個模型的收斂曲線形狀相近，QNN 始終落後 MLP 約 2-3 個百分點，且在 epoch 20 仍有微幅上升的趨勢。

(e) 討論

電路規模的關鍵作用

從 $4q \times 2l$ (Hilbert space $2 = 16$ 維) 升級至 $8q \times 4l$ ($2 = 256$ 維), QNN 的測試準確率從 61.07% 躍升至 73.70%, 提升了整整 12.63 個百分點。最顯著的改善出現在原本最弱的類別: cat 從 13.5% 提升至 41.8%, bird 從 28.2% 提升至 62.9%。這說明舊版電路的失敗主要源於表達容量不足, 而非量子電路本質上不能做視覺分類。

批次平行化消除速度瓶頸

`torch.func.vmap` 將每個 batch 內 64 次 sequential QNode 呼叫合併為 1 次 vmapped 呼叫, 消除了 Python 迴圈的 overhead, 使 QNN 訓練時間從 18,250 秒壓縮至 658 秒 (快 27 $\times$)。即使使用更大的電路 ($8q \times 4l$), 整體訓練時間仍只比 MLP 慢 10 倍, 已進入可以實際迭代實驗的範圍。

仍存在的差距分析

epoch 20 的差距 (2.76%) 主要來自三個方面:

1. **收斂尚未完成**: QNN epoch 20 的訓練準確率仍在緩慢上升 (73.55%), 延長訓練可能進一步縮小差距。
2. **cat 類別的固有難度**: MLP 的 cat 也只有 57.5%, 顯示這是 backbone 特徵的問題, 而非分類頭的問題。
3. **線性 vs 量子頭的容量差異**: MLP 的 Linear(256 $\rightarrow$ 10) 可以直接在 256-D 全空間做分類; QNN 仍需先壓縮至 8-D 再做量子處理, 中間線性瓶頸略微限制了資訊傳遞。

結論

在相近參數量 (~58K) 的條件下, $8q \times 4l$ + vmap 的量子分類頭達到了 73.70% 的測試準確率, 與 MLP (76.46%) 僅差 2.76 個百分點, 且訓練時間已從小時級別降至分鐘級別。這表明量子電路在具備足夠的表達容量 (qubits 數) 與有效的訓練策略 (vmap 批次平行) 之後, 能夠在現實尺度的影像分類任務上與同等規模的古典模型相互競爭。